

## Definição da tecnologia



- Armazém de dados
- Coleção de dados orientada a assunto
- Características:
  - Base SQL
  - Pré-processamento
  - Visualização
  - ML/AI
- Otimizada

- Diversas tecnologias
- Data Mart
- Data Lake

## Introdução

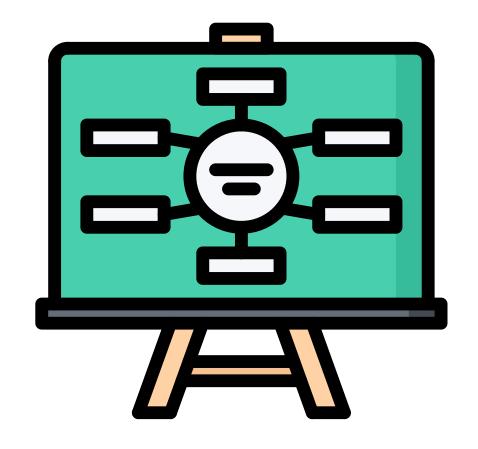


- Base de dados foi encontrada no Kaggle
- Base de dados sobre tweets da eleição dos EUA.
- Base de Dados no formato de arquivo csv
- O porquê essa base de dados foi escolhida

### Schema de um data Warehouse

#### Conceitos

- Fact tables que são tabela principal que reúne os atributos das tabelas secundárias mais os seus próprios atributos principais (exemplo: valor total da venda);
- Dimension tables, tabela secundária de características sobre a tabela principal (exemplo: horário que a venda foi realizada).



#### Modelando o Banco



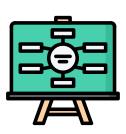
- Análise do CSV
- Modelagem SQL
- <u>Script Python</u> para tratamento dos dados
  - ETL(Extract Transform Load)
  - Pandas
  - SQLAlchemy





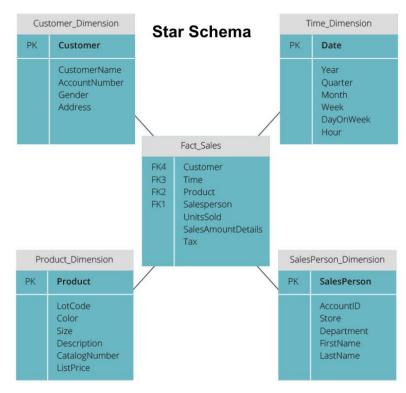


## Escolha de um Schema



#### Star Schema

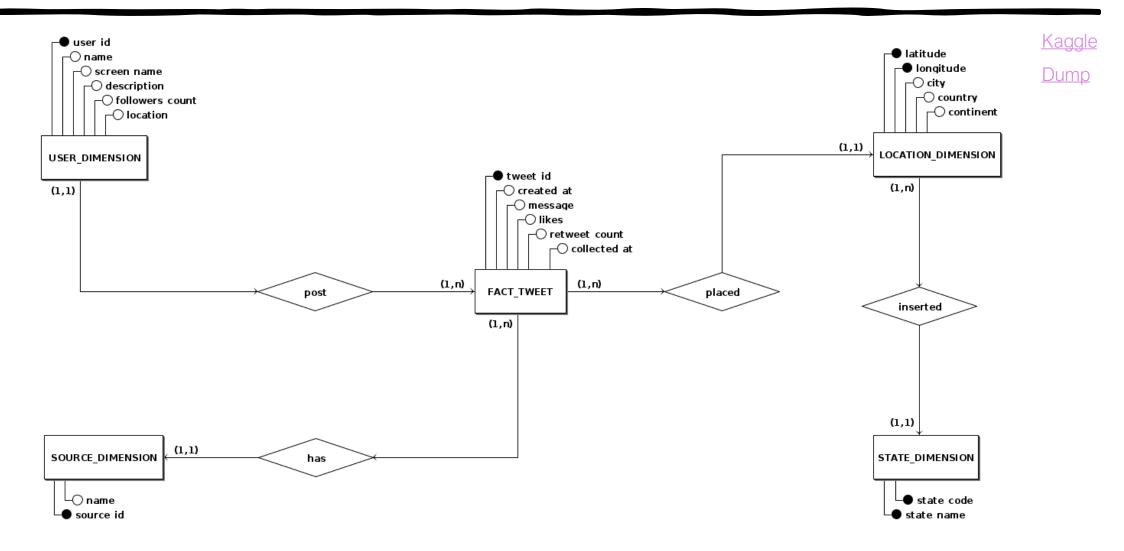
- Dividir fact table em dimension tables desnormalizadas.
- Maior velocidade de consultas por realizar apenas uma junção das dimension tables com a fact table.
- Escolha mais adequada para o contexto



Legend: PK = primary key | FK = foreign key

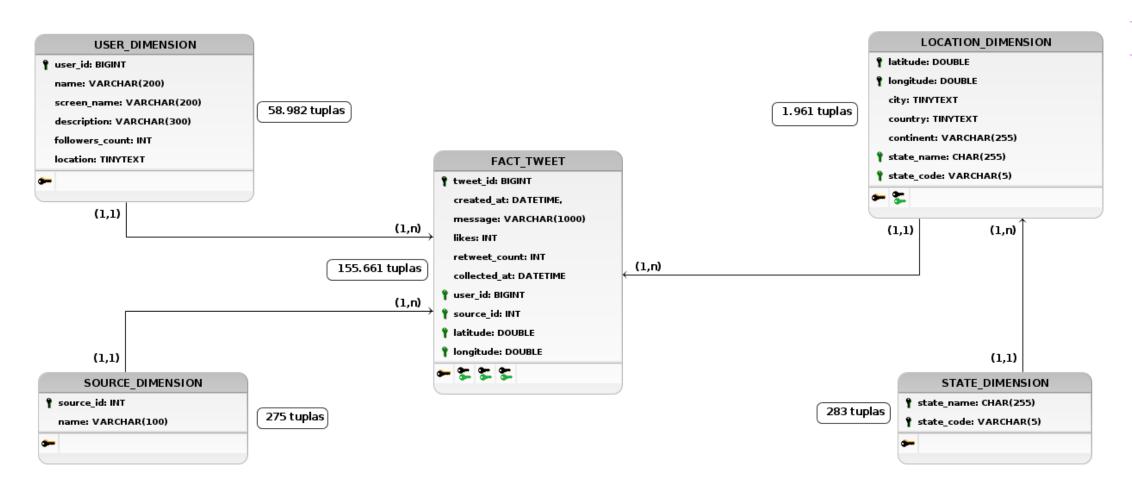
# Documentação da Base de Dados 📃





## Documentação da Base de Dados 📜





Kaggle

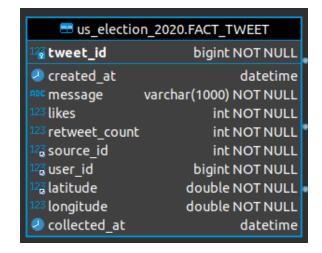
Dump

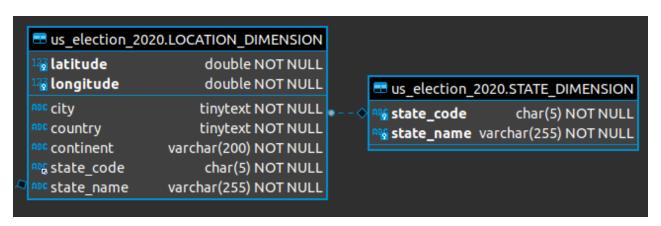
## Trabalhando com Big Data

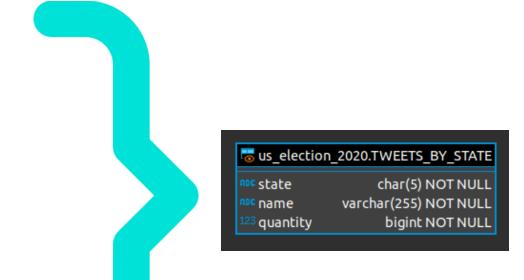


- Dump gerado
- Problemas com exportação de dados (Enconding)
- Inserts do Dump
- Formatação via Regex







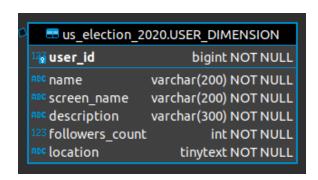




SELECT * FROM TWEETS_BY_STATE LIMIT 10 123 Enter a S									
	noc state ₹‡	ABC name T:	123 quantity <b>\(\tau</b> :						
1	NY	New york	18,112						
2	CA	California	15,935						
3	ENG	England	11,786						
4	DC	District of columbia	6,703						
5	TX	Texas	6,691						
6	IDF	Ile-de-france	6,669						
7	FL	Florida	5,405						
8	IL	Illinois	3,478						
9	DL	Delhi	3,477						
10	ON	Ontario	3,280						



■ us_election_2020.FACT_TWEET						
¹ॡ tweet_id	bigint NOT NULL					
created_at	datetime					
nessage message	varchar(1000) NOT NULL					
<sup>123</sup> likes	int NOT NULL					
<sup>123</sup> retweet_count	int NOT NULL					
¹²a source_id	int NOT NULL					
¹²ಡ user_id	bigint NOT NULL					
12a latitude	double NOT NULL					
<sup>123</sup> longitude	double NOT NULL					
collected_at	datetime					





us\_election\_2020.USERS\_ANALYTICS

123 id bigint NOT NULL

123 followers int NOT NULL

123 qtd\_tweets bigint NOT NULL

123 likes\_avg decimal(14,4)

123 retweet\_avg decimal(14,4)



SELE	CT * FROM USERS_ANALYTIC	CS WHERE likes_avg	BI Enter a SQL	Lexpression to filter i	results (use Ctrl+S <sub>i</sub>	pace)
	123 jd \\\\\\\\\\\\\\\\\\\\\\\\\\\\\\\\\\\	asc username 🚺	123 followers <b>T</b> :	123 qtd_tweets Ҭ:	123 likes_avg <b>T</b> :	123 retweet_avg 🚺
1	105,165,371	andrebercoff	88,139	5	2,243.8	797.4
2	550,377,428	AshokShrivasta6	101,742	3	2,407.6667	373.3333
3	19,409,508	bobbyberk	444,512	2	2,854.5	102
4	2,329,492,448	OliviaTroye	118,266	2	2,813	608.5
5	18,208,368	kurtbardella	68,810	2	2,757.5	847
6	509,981,951	PorcherThomas	96,998	2	2,608	595
7	196,401,315	johndelancie	71,438	2	2,127	407
8	394,250,799	Br4mm3n	335,858	2	2,063	14.5
9	1,591,400,760	TaraSetmayer	105,668	2	2,011	178
10	56,039,856	abhijitmajumder	547,842	1	2,797	956
11	87,643,561	Rajput_Ramesh	91,070	1	2,749	231
12	1,066,505,848,791,474,176	FamilyKabs	38,636	1	2,605	352
13	14,085,099	KDKA	193,015	1	2,525	683
14	1,664,075,966	HeatherTDay	38,102	1	2,348	92
15	412,591,867	masonsixtencox	39,062	1	2,299	99
16	393,421,515	BernardineEvari	52,353	1	2,268	99
17	74,169,715	MzKatieCassidy	671,142	1	2,248	139
18	122,104,353	c_lindner	414,994	1	2,199	115
19	14,957,147	TheYoungTurks	429,163	1	2,123	469
20	1,249,274,011,109,949,440	TorreyHarris901	1,508	1	2,035	204

#### Ferramentas



- DBeaver
- MySQL Workbench
- Vscode
- BrModelo



